Laporan Sementara: GMM-Based Fusion Router

Amazon Reviews 2023 (Appliances), dataset penuh (semua review Appliances yang punya gambar) · seed 42, 43, 44 · 2026-10-29

Status: hasil **validasi** saja. Test set belum dipakai; test dijalankan sekali setelah kode lolos inspeksi.

Ringkasan

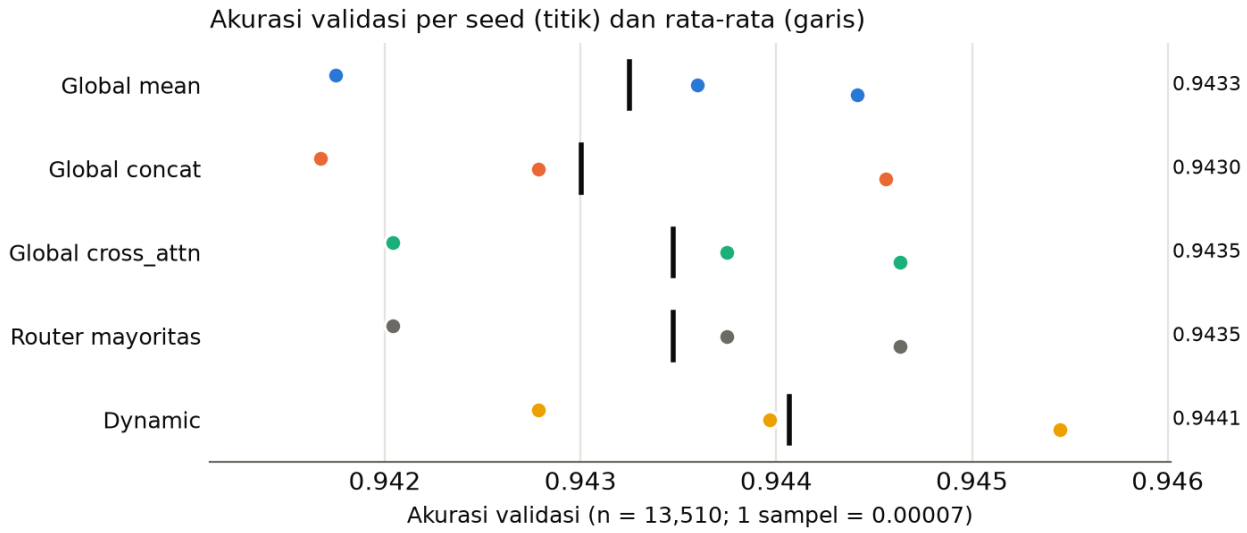
Di validasi (13,510 sampel), Dynamic Fusion sedikit **di atas** fusion global terbaik pada setiap seed (seed 42: 0.9454 vs cross_attn 0.9446 (+11 sampel); seed 43: 0.9440 vs cross_attn 0.9437 (+3 sampel); seed 44: 0.9428 vs cross_attn 0.9420 (+10 sampel)). Rata-rata Dynamic 0.9441 vs rata-rata satu metode terbaik 0.9435. Skor Dynamic di validasi bias optimis karena konfigurasinya dipilih dari 140 kandidat di validasi yang sama.

Pembanding yang adil adalah kontrol permutasi, yaitu seluruh seleksi diulang dengan label router diacak (seed 42: asli 0.9454, acak rata-rata 0.9456, p = 0.86, seed 43: asli 0.9440, acak rata-rata 0.9442, p = 1.00, seed 44: asli 0.9428, acak rata-rata 0.9427, p = 0.05). Hanya 1 dari 3 seed yang melewati persentil ke-95 (dengan 20 permutasi, p terkecil yang mungkin 0.048). Router memilih metode terbaik per sampel dengan akurasi 0.32, sedangkan selalu memilih cross_attn mendapat 0.43. Jadi **belum ada bukti** bahwa router berbasis GMM belajar memilih fusion yang tepat.

Apa yang dilakukan

1. Tiga model fusion (mean, concat, cross_attn) dilatih di train (54,039 sampel), checkpoint dipilih di validasi.
2. Label router = metode dengan probabilitas kelas benar tertinggi, dihitung dari prediksi 5-fold di train (model tidak pernah melihat sampel yang ia beri label).
3. GMM pada embedding gambar + judul + teks (standarisasi → PCA → GMM, fit di train) memberi probabilitas cluster per sampel.
4. MLP router: probabilitas cluster → metode fusion. K, PCA, kovarians, dan MLP dipilih di validasi (140 kandidat).
5. Kontrol permutasi: seluruh seleksi diulang 20 kali dengan label router diacak.

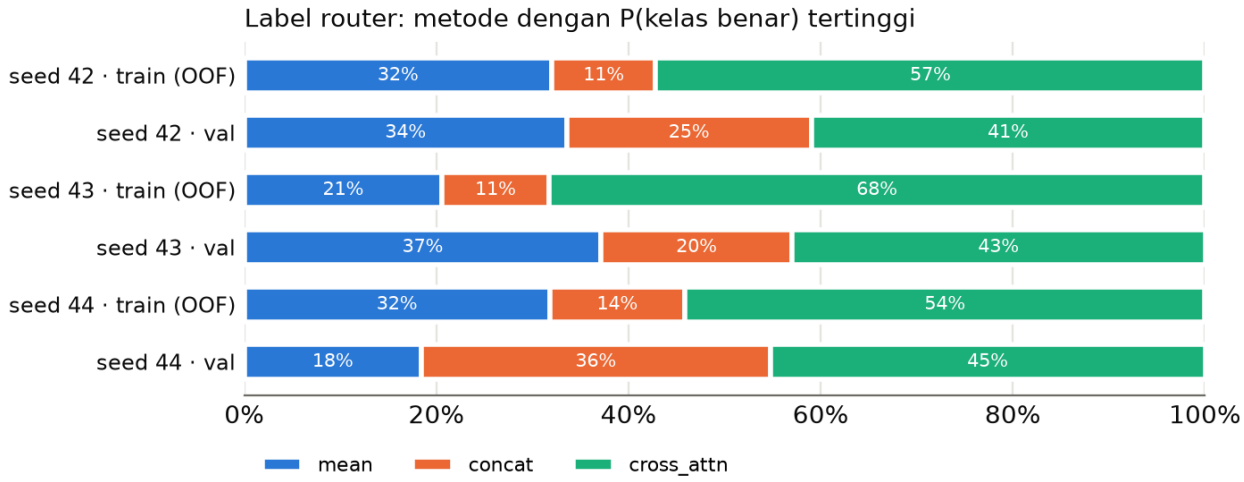
Hasil



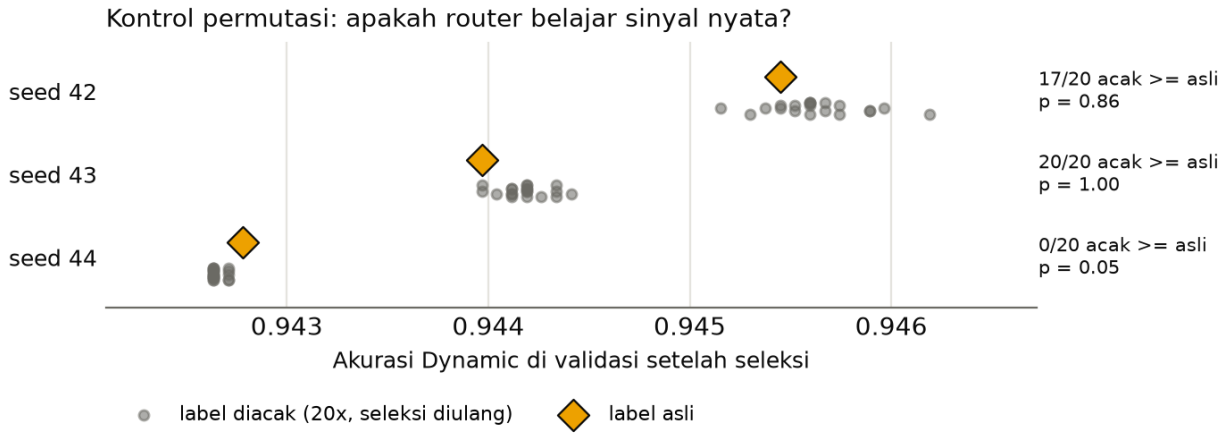
Gambar 1. Akurasi validasi. Satu sampel = 0.00007; seluruh selisih di gambar ini paling banyak 51 sampel dari 13,510.

Tabel 1. Konfigurasi terpilih dan skor validasi per seed.

Seed	GMM terpilih (PCA, kov., K)	Router	Dynamic	Global terbaik	Akurasi router	p permutasi
42	16, diag, 3	32 / balanced	0.9454	cross_attn 0.9446	0.23	0.86
43	64, diag, 3	32 / balanced	0.9440	cross_attn 0.9437	0.33	1.00
44	32, full, 8	16 / balanced	0.9428	cross_attn 0.9420	0.39	0.05



Gambar 2. Distribusi label router (metode terbaik per sampel). Label terbanyak di validasi: seed 42: cross_attn 41%; seed 43: cross_attn 43%; seed 44: cross_attn 45%. Label train (OOF, model fold) dan validasi (model penuh) berbeda distribusinya.



Gambar 3. Skor router dengan label asli (kuning) vs router dengan label acak (abu-abu). Jumlah permutasi dengan skor >= asli per seed: 17/20, 20/20, 0/20.

Kesimpulan sementara

• Pipeline berjalan lengkap di data ini. Checklist kebocoran data lolos pemeriksaan reviewer internal dan seluruh tes otomatis lolos; inspeksi independen (Codex) atas perbaikan terakhir belum selesai.
• Ketiga fusion global hampir setara di validasi (dalam satu seed, selisihnya paling banyak 13 dari 13,510 sampel), sehingga label 'metode terbaik per sampel' sebagian besar ditentukan oleh selisih confidence yang sangat kecil.
• Langkah berikutnya: (1) inspeksi kode oleh Codex, (2) jalankan test sekali untuk perbandingan akhir Dynamic vs Global.

Sumber angka: results/appliances_full/<run_id>/router_selection/seed*.json dan full_val/*.json (hash diverifikasi saat laporan dibuat). Run select: seed 42=11b48e13ac02, seed 43=68a734194d12, seed 44=4704ebc9a41f